

#	진행 순서	전처리 변경점	모델 변경점	🔄	사용 모델	f1 스코어	#	AUC점수	등락	비고 및 변경 이유
	예시)	이상치 -> 평균치	파라미터 조정		Decision Tree			0.5000	--	
1		가격 이상치 제거(0원 ↓/2,000불↑) + log1p 변환	-		-					정제 후 1,481,609행
2		category_name → Main/Sub/SubSub 3단계 분리	-		-					train 기준 unseen 조합은 Unknown 처리
3		train/test 분리 (8:2)	-		-					random_state=42
4		brand_name 결측치 매칭	-		-					train 사전 4,535개, description 매칭
5		brand/category unseen 값 Unknown 통일	-		-					test는 사전 적용만, 재생성 안 함
6		텍스트 클렌징 (소문자화+숫자유지+불용어 제거)	-		-					name, item_description 공통 적용
7		TF-IDF 백터화	-		-					name 3만 / description 5만
8		원-핫 인코딩 + 수치 스케일링	-		-					brand/category 5,527차원 + item_condition_id
9		Feature 결합 (전처리 파이프라인 저장)	-		-					최종 85,529차원
10		-	베이스라인 모델 학습		Ridge (alpha=1.0)	N/A (회귀 과제)		0.4589	--	RMSLE 기준(낮을수록 좋음). 숫자 제거 버전
11		텍스트 숫자 유지로 변경	-		Ridge (alpha=1.0)	-		0.4560	-0.00295	4gb/32gb 등 사이즈 정보 보존 → 개선
12		-	Ridge alpha 스윙 (1,2,3,4,5)		Ridge (alpha=3.0)	-		0.4545	-0.0015	alpha=3.0 최적 (U자 곡선)
13		-	GBM 계열(LightGBM) 추가		LightGBM (150라운드, 빠른검증)	-		0.5205	0.06598	빠른모드라 아직 Ridge보다 나쁨
느낀점	데이터를 확인하면서 여러 가설을 세워가며 데이터 전처리하는 부분에서 많은 생각을 할 수 있었다. 다만 그 부분이 정답은 아닌지라 최대한 얻을 수 있는 정보를 얻어가며 진행하였고, 그 중간에 필요한 부분들은 어떤 부분들이 있는지 내가 도출해내는 데이터의 형태에 따라 써야되는 함수와 데이터타입을 바꾸는 함수 등 여러 부분들을 알 수 있었다. 두가지 모델을 시도해보면서 빠르지만 비교적 점수는 안좋은 모델을 써야하는가와 약 97분이 걸리더라도 그리고 더 나아질 여지가 있어 더 시간을 투자하더라도 성능이 좋은 모델을 써야하는지 많은 고민이 들었지만 역시 현장에서 요구하는바, 혹은 서비스에 대한 부분을 생각했었을 때, 시간이 오래 걸리더라도 좀 더 정확하게 예측해줄 수 있는 모델을 선택하는 것이 낫겠다 라는 결론이 나오긴했다. 추가적으로 작업해보고 있는 방향은 description 외에 name 에서도 브랜드 이름을 가져와서 추가적으로 brand 사전에 기입해두고 매칭해보는 방향으로 시도해보고 있다. 다만 이렇게 되실 브랜드이름은 많아지더라도 잘못 가져와서 입력되어 오탕할 가능성도 높아진다.									