

#	진행 순서	진행 과정	모델 변경점	사용모델	점수	등락	비고
	예시)	이상치 -> 평균치	파라미터 조정	Decision Tree		-	
	1					0	
	2					0	
	3					0	
	4					0	
	5					0	
	6					0	
	7					0	
	8					0	
	9					0	
	10					0	
	11					0	
	12					0	
	13					0	
	14					0	
	15					0	
	16					0	
종합 느낀점		메르카리를 하면서 가장 크게 남은 건, "좋아 보이는 것"과 "실제로 효과가 있는 것"이 다르다는 점이였다. category_name을 몇 조각으로 나눌지, 정규식에서 숫자를 남길지 같은 사소한 보이는 선택도 직접 데이터로 비교해 보기 전에는 판단하기 어려웠다. 실제로 카테고리 분리 방식은 결과에 거의 영향이 없었고, 숫자 보존은 RMSLE를 0.7%쯤 꾸준히 낮췄다. 작지만 확인하지 않으면 몰랐을 차이다. 모델 쪽에서는 화려한 모델보다 문제 구조에 맞는 모델이 중요하다는 걸 체감했다. 8만 개가 넘는 희소한 텍스트 피처에서는 계수를 조금씩 줄이는 Ridge가 가장 잘 맞았고, 반대로 Lasso는 규제가 세게 걸려 피처의 99% 이상을 0으로 만들어 버려서 오히려 과소적합했다. LGBM도 튜닝 없이는 Ridge를 넘지 못했다. alpha를 5개로 나눠 튜닝해 봤지만 차이는 미미했고, 성능을 좌우한 건 결국 모델보다 전처리와 피처 구성이였다. 지표를 다루면서 RMSLE가 "log를 씌운 상태에서의 RMSE"라는 걸 정확히 이해하는 것도 은근히 중요했다. 타깃을 이미 log1p 했는데 여기에 또 log를 씌우면 이중 계산이 된다는 걸 정리하면서, 지표 정의를 대충 넘기면 안 된다는 걸 배웠다. 아쉬운 점은 데이터가 커서 전체로 교차검증을 제대로 못 돌린 것, 그리고 텍스트 임베딩이나 모델 앙상블까지는 시도하지 못한 것이다. 다만 잔차 분포와 카테고리별 오차를 시각화해 보니 어느 구간에서 모델이 약한지 감을 잡을 수 있었다.					