

#	진행 순서	진행 절차	전처리 변경점	모델 변경점	결과 및 확인 지표	📄	사용모델	RMSLE	등락	6월
	예시)	이상치 → 평균치	파라미터 조정				Decision Tree		--	
		데이터 로드 및 결측치/이상치 1차 진단	TSV 로드, price=0인 행(8262건) 및 컬럼별 결측치 현황 진단		데이터 크기(148만건), 가격 기초 통계량 파악					
2		중복 및 이상치 정제 / ID 제거	중복행 제거, price > 0 & price < 2000 필터링, train_id 컬럼 삭제		전처리 후 데이터 148만건 정제 완료					
3		타깃 변수 정규화 (EDA)	타깃 변수 price에 log1p 변환 적용		가격 분포 우측 왜도(Skewness) 완화 확인					
4		범주형 및 카테고리 피쳐 엔지니어링	category_name 대/중/소 3단계 분할, shipping/상태값 확인		대분류별 거래량 및 평균 가격대 차이 확인					
5		텍스트 클리닝 및 결측치 대체	결측치 'Other_Null' 대체, 영문/숫자 클리닝, 부정어 (without 등) 보존 및 'rm' 불용어 제거		item_description 정제 텍스트 추출					
6		Train / Test 사전 분할 (누수 방지)	8:2 사전 분할 (random_state=42)		텍스트/인코더 사전 학습 전 Test 데이터 완전 격리					
7		피쳐 벡터화 및 원-핫 인코딩	Train 기준으로만 fit_transform, Test는 transform 적용 (TfidfVectorizer max_features=50,000, LabelBinarizer)		CSR 희소 행렬 변환 및 상위 20개 중요 단어 확인					
8		희소 행렬 결합 (hstack) 최적화	설명글 제외/포함 4중 희소 행렬 사전 1회 결합 및 개별 행렬 메모리 해제 (gc.collect)		결합 행렬 shape 확정, 연산 중복 제거					
9		설명글 제외 기본 Ridge 모델 학습	item_description 제외 피쳐 조합 (제목, 브랜드, 상태, 배송, 카테고리)	Ridge (solver='lsqr', fit_intercept=False, alpha=3)	설명글 미포함 기준선 성능 측정	Ridge		0.4932	-	
10		설명글 포함 Ridge 모델 (정규화 튜닝)	item_description 포함 전체 피쳐 조합	Ridge (alpha=0.1 → 1 → 2 → 3 → 4 → 5 튜닝 후 3 채택)	텍스트 피쳐 추가로 인한 오차 대폭 감소 확인	Ridge		0.4593	-0.0339	
11		비선형 트리 모델 (LightGBM) 학습	item_description 포함 전체 피쳐 조합	LightGBM (n_estimators=200, learning_rate=0.5, num_leaves=125)	선형 모델 대비 비선형 피쳐 상호작용 학습 성능 개선	LGBM		0.4507	-0.0086	
12		Ridge + LightGBM 앙상블	item_description 포함 전체 피쳐 조합	가중 평균 앙상블 (Ridge 0.45 : LightGBM 0.55)	상호 보완적 결합을 통한 최저 오차 달성	Ridge, LGBM		0.4401	-0.0106	
13		LightGBM 1차 튜닝 (조기 종료 및 검증 최적화)	item_description 포함 전체 피쳐 조합 유지	포함 전체 피쳐 조합 유지 LightGBM (lr=0.15, num_leaves=63, n_estimators=1000, early_stopping=30, Test 세트만 실시간 평가)	속도 유지(약 8분) 및 오차 개선	LGBM		0.4422		
14		LightGBM 2차 튜닝 (정밀 보폭 및 트리 확장)	item_description 포함 전체 피쳐 조합 유지	LightGBM (lr=0.05, num_leaves=127, n_estimators=3000, min_child_samples=50, colsample_bytree=0.7, early_stopping=50)	오차 개선, 속도는 약 20분 소요	LGBM		0.4353		
15		LightGBM 3차 튜닝 (극한 정밀화 및 정규화 적용)	item_description 포함 전체 피쳐 조합 유지	LightGBM (lr=0.03, num_leaves=255, n_estimators=4000, subsample=0.8, colsample=0.7, reg_alpha=0.1, reg_lambda=1.0, max_bin=512, early_stopping=60)	단일 모델 기준 최저 오차(0.4291) 달성, 속도는 200분 소요	LGBM		0.4291		
16										
느낀점		이번 메르카리 프로젝트를 통해 비정형 텍스트 피쳐 엔지니어링과 대용량 데이터 파이프라인 최적화의 중요성을 깊이 체감했습니다. 상품명에는 CountVectorizer, 본문 설명글에는 TfidfVectorizer(ngram_range=(1, 2))를 데이터 성격에 맞게 차별 적용하여 문맥과 핵심 키워드를 효과적으로 피쳐화했습니다. 특히 140만 건에 달하는 대규모 희소 데이터를 다루면서 Train/Test 분할 전 벡터화로 발생할 수 있는 데이터 누수를 방지하기 위해 엄격한 사전 분할과 fit_transform 분리를 적용했습니다. 또한 모델링 전 희소 행렬을 사전에 1회만 결합하고 메모리를 즉시 반환하도록 설계하여 연산 효율과 안정성을 크게 높였습니다. 모델링 단계에서는 희소 행렬 연산에 최적화된 Ridge(solver='lsqr')의 규제 강도를 튜닝해 기준 성능을 다진 뒤, LightGBM을 단계별로 튜닝해 나갔습니다. 조기 종료와 피쳐, 데이터 서브샘플링, 그리고 L1/L2 복합 정규화를 정밀하게 적용하여 고차원 희소 피쳐의 과적합을 방지하고 비선형 패턴을 학습시켰습니다. 그 결과 3차 정밀 튜닝을 거친 LightGBM 단일 모델만으로 기존 앙상블을 넘어서는 최저 RMSLE(0.4291)를 달성하면서 데이터 구조와 알고리즘 특성에 맞춘 하이퍼파라미터 최적화의 가능성을 크게 실감할 수 있었습니다.								