

[회의록] 2과 보고서 마무리 및 3과 텍스트 군집화 분석 회의

- 일시: 8월 25일
- 참석자: 진희, 혜현, 유경, 소현, 용우

회의 안건 및 결정 사항

1. 2과 보고서 제출 자료 및 일정 정리 (1차 회의)

- 제출 및 공유 자료
 - 코드 실행 결과가 포함된 HTML 파일 제출
 - 시각화 자료는 이미지 파일로 다운로드 후 공유 폴더에 업로드 (파일명 규칙 준수)
- 오전 일정: 2과 내용 정리 마무리 및 3과 데이터 분석 병행 (3과 데이터 탐색 및 수업 실습 내용 복습)

2. 3과 텍스트 데이터 전처리 및 군집화 모델링 방향 (2차 회의)

- 텍스트 전처리 세부 방안
 - 정제 및 정규화: 소문자화, 특수문자 제거, 토큰화, 1글자 노이즈 제거, 불용어 처리/조정
 - 표제어 추출(Lemmatization): 단어 원형 복원(`LemTokens`) 적용. 단, 과거형 시제 정보 유지를 위해 진희님은 해당 단계를 제외하고 비교 진행
- TF-IDF 벡터화 설정 (수업 실습 코드 기반)
 - `tokenizer=LemNormalize` (사용자 정의 전처리 엔진 연결)
 - `ngram_range=(1, 2)` (연속 단어 조합 생성, 필요시 조정)
 - `min_df=0.05` , `max_df=0.85` (희귀/과다 빈출 단어 필터링)
 - 희소 행렬 처리 및 고차원 피쳐 대응을 위해 PCA 적용 고려
- 군집화(Clustering) 모델 선정
 - `K-Means` 는 공통 필수로 반드시 적용
 - 추가 모델(DBSCAN, GMM, 계층적 군집화/Agglomerative, LDA 등) 및 클러스터 개수(k)는 개인별로 자유롭게 선택하여 진행

3. 시각화 규칙 및 향후 일정 (3차 회의)

- 시각화 자료 규칙: 그래프 및 시각화 차트 제목은 **영문**으로 통일

- **마감 일정:** 3과 데이터 분석 작업은 **당일(8/25) 내 완료**
- **보고서 작성:** 익일 오전 진행 예정