

# [회의록] 4과 데이터 분석 및 전처리/모델링 방향 회의

- 일시: 8월 26일
- 참석자: 진희, 혜현, 유경, 소현, 용우

## 회의 안건 및 결정 사항

### 1. 4과 일정 및 분석 방향 설정 (1차 회의)

- 진행 일정
  - 목요일: 4과 데이터 분석 및 모델링 완료
  - 금요일: 4과 최종 보고서 작성
- 데이터 분석 방향
  - 텍스트와 범주형(카테고리) 변수가 혼합된 구조이므로 철저한 컬럼 분석 선행 후 모델 선정
  - 식별자 컬럼(`train_id`)은 분석 및 학습에서 제외 고려
  - 차기 회의 전까지 공통 전처리 흐름 구체화해 오기로 결정

### 2. 데이터 전처리 및 모델링 방향 논의 (2차 회의)

- 공통 전처리 기준
  - 중복 데이터 제거
  - `price == 0` 인 이상치 행(827건) 제거
  - 타깃 변수(`price`)의 `log1p` 로그 변환 적용
  - 피처 처리: 텍스트 데이터는 벡터화, 범주형 데이터는 원-핫 인코딩(선택적) 적용 후 로그 스케일 타깃으로 학습
- 결측치 및 카테고리 처리 아이디어 (개인별 접근)
  - 진희: `name` / `brand_name` / `category` 를 결합하여 결측치 보완(예: 브랜드가 비어 있어도 상품명에 'Nike' 포함 시 추출) 및 빈도수 기반 고가치 단어 탐색
  - 유경: 수업 실습 방식 기반으로 카테고리 계층 구조(대/중/소) 분리 적용
  - 용우: 카테고리를 대/중/소로 분할하여 신규 데이터프레임 구성
  - 불용어 처리: 기본 불용어 외 추가 정제는 개인별로 유연하게 진행
- 모델 선정: 텍스트/희소 행렬 처리에 강한 **Ridge** 및 **LightGBM** 중심으로 진행

### 3. 데이터 분할 및 검증 방식 논의 (3차 회의)

- **Train/Test 데이터 분할( `train_test_split` ) 시점 논의**
  - **용우 방식:** 전처리 시작 전 최상단에서 분할하여 데이터 누수(Data Leakage) 완전 방지
  - **팀원 방식:** 전체 전처리 완료 후 분할 진행
  - **보완 검증 방안:** 전처리 로직이 Train 세트에 종속될 경우 Test 세트에서 오류가 발생할 수 있으므로, 하단에서 학습한 모델을 사전 분할된 독립적인(Fresh) Test 세트로 최종 검증하는 방식 검토
- **불용어 코드 공유:** 필수 적용할 공통 불용어 처리 코드는 전체 코드 공유 시 함께 첨부하기로 결정